پروپوزال پژوهشی

گواه ازسرگیری
در گردش کار عامل‌های هوش مصنوعی

اعتبارسنجی تطبیقی پیش‌شرط‌ها پس از وقفه با بودجه‌ی محدود مشاهده

ResumeCert
Budgeted Evidence for Workflow Resumption after External State Changes

پژوهشگر پیشنهادی: یوسف ابوالفتحی روزبهانی

تاریخ: ۱۱ نوامبر ۲۰۲۶

حوزه: هوش مصنوعی عامل‌محور و قابلیت اعتماد اتوماسیون

چکیده

عامل هوش مصنوعی ممکن است پس از وقفه، قدم بعدی یک گردش کار را درست به یاد بیاورد، اما در زمان بازگشت دیگر مجاز به اجرای آن نباشد. این پژوهش می‌سنجد که آیا خواندن تطبیقی وضعیت جاری، با بودجه‌ی ثابت، پوشش تصمیم‌های قابل اثبات برای ادامه یا رد همان قدم را افزایش می‌دهد. در آزمایش محاسباتی پیشنهادی، وضعیت قبل از وقفه، تاریخچه و پیام ازسرگیری در دو سناریوی جفت ثابت می‌مانند و اعتبار قدم بعدی با یک تغییر کنترل‌شده در محیط برمی‌گردد. سیاست خواندن فقط از طریق ابزارهای هزینه‌دار به وضعیت تازه دسترسی دارد. داور مستقل، تصمیم و گواه آن را با وضعیت واقعی شبیه‌ساز و قرارداد اقدام می‌سنجد.

مقایسه‌ی اصلی بین سیاست تطبیقی و قوی‌ترین خط پایه‌ی اجرایی تثبیت‌شده در توسعه انجام می‌شود. شمارش دقیق در فضای محدود حالت، مرز کفایت مشاهده را از خطای انتخاب خواندن و خطای تصمیم جدا می‌کند. پایلوت با ۲۴ جفت و آزمون تاییدی با ۴۸ جفت در دو خانواده‌ی کنارگذاشته‌شده طراحی شده‌اند. یک مثال صوری هشت‌حالته بازتولید شده است؛ اثر روش در بنچمارک و محیط واقعی هنوز اندازه‌گیری نشده است. خروجی پژوهش، قرارداد اجرایی، مجموعه سناریوها، داور قطعی و گزارش بازتولیدپذیر هزینه و کیفیت تصمیم خواهد بود.

واژگان کلیدی: ازسرگیری وظیفه، عامل هوش مصنوعی، مشاهده‌ی جزئی، اعتبارسنجی پیش‌شرط، گواه تصمیم، گردش کار.

بخش ۱

بیان مسئله و اهمیت پژوهش

نقطه‌ی ذخیره به عامل می‌گوید در کجای گردش کار بوده است. اعتبار قدم بعدی به وضعیت محیط در زمان بازگشت بستگی دارد. برای نمونه، تایید انتشار به نسخه‌ی سند وابسته است؛ اگر سند هنگام وقفه تغییر کند، به خاطر سپردن کامل دستور و تایید قبلی، مجوز انتشار نسخه‌ی تازه را ثابت نمی‌کند. از طرف دیگر، بازخوانی همه‌ی وضعیت هزینه‌ی فراخوان، زمان یا پردازش دارد. این تضاد زمانی مهم می‌شود که عامل به چند منبع دسترسی دارد و باید پیش از پایان بودجه تصمیم بگیرد.

مرحله	آنچه در نمونه‌ی انتشار رخ می‌دهد	آنچه عامل مجاز است ببیند
پیش از وقفه	نسخه‌ی گزارش با تایید معتبر در صف انتشار است.	تاریخچه، قدم بعدی و مقدارهای ذخیره‌شده
هنگام وقفه	نسخه‌ی گزارش عوض می‌شود؛ تایید قبلی باقی می‌ماند.	بدون مشاهده‌ی مستقیم تغییر
پس از وقفه	انتشار فقط با تایید معتبر برای نسخه‌ی جاری مجاز است.	پیام ازسرگیری و پاسخ خواندن‌های هزینه‌دار

اهمیت علمی

سنجش صرف موفقیت نهایی مشخص نمی‌کند شکست از کهنگی وضعیت، ناکافی بودن مشاهده، انتخاب بررسی نامناسب یا برداشت غلط از شواهد آمده است. این پژوهش برای یک اقدام ثابت، دسترسی به اطلاعات، امکان اثبات و تصمیم نهایی را جدا اندازه می‌گیرد. جفت‌های کنترل‌شده اجازه می‌دهند تغییر اثرگذار بر تصمیم از تغییر ظاهری پیام یا موضوع جدا شود. مقایسه در هزینه‌ی یکسان نشان می‌دهد بهبود احتمالی از ترتیب خواندن حاصل شده یا فقط از مشاهده‌ی بیشتر.

اهمیت کاربردی

انتشار مستند، ارسال سفارش ساختگی و ثبت سند در یک دفتر، سه نمونه از گردش کارهایی هستند که در آن‌ها قدم بعدی به نسخه، تایید یا سابقه‌ی اجرا وابسته است. یک گواه قابل بررسی به مسئول گردش کار توضیح می‌دهد عامل به چه مشاهده‌ای اتکا کرده، کدام نسخه‌ی قرارداد را به کار برده و چرا ادامه داده یا تصمیم را به تعویق انداخته است. نتیجه‌ی پژوهش می‌تواند به انتخاب میان کنترل ساده‌ی نسخه و بازخوانی تطبیقی کمک کند.

واحد تحلیل، یک اقدام پیشنهادی در نقطه‌ی ازسرگیری است. برنامه‌ریزی کامل، اجرای واقعی عملیات و بازیابی کل تاریخچه در آزمایش اصلی اندازه‌گیری نمی‌شوند.

بخش ۲

پیشینه و شکاف پژوهشی

در آزمایش شناختی آلتمن و همکاران، وقفه‌ی کوتاه خطاهای حفظ جایگاه در یک توالی را افزایش داد [1]. در مطالعه‌ی نگوین و همکاران، خطای پیش‌بینی و عدم‌قطعیت پیش‌بینی به‌عنوان دو توضیح برای مرزبندی رویداد با داده‌ی تصویربرداری کارکردی آزموده شدند [2]. پژوهش گولر و همکاران نیز با دو شاخص EEG به بررسی نقش حافظه‌ی کاری در گذار رویداد پرداخت [3]. استنباط طراحی حاضر، جدا کردن برجستگی سرنخ از عدم‌قطعیت درباره‌ی اقدام است. هیچ نتیجه‌ای درباره‌ی سازوکار مغز از شبیه‌ساز عامل استنباط نخواهد شد.

کار نزدیک	آنچه سنجیده است	متغیر متمایز در این پژوهش
ContinuityBench [4]	وقفه‌ی کنترل‌شده و کیفیت اطلاعات تحویل در بازیابی عامل.	تحویل ثابت است؛ اعتبار اقدام در وضعیت تازه عوض می‌شود.
PM-Bench [5]	قصد معوق، کانال وضعیت پنهان و هزینه‌ی پایش.	اعتبار همان اقدام مشخص با خواندن محدود و گواه تصمیم.
Async-RBench [6]	واکنش به نتیجه‌ی ناهمگام و الزام به بازبینی برخی وضعیت‌ها.	مقایسه‌ی سیاست‌های خواندن با بودجه‌ی یکسان و سقف صوری.
EnvTrustBench [7]	اعتماد نابه‌جا به مشاهده‌ی کهنه یا گمراه‌کننده.	جفت‌های هم‌تاریخچه و تفکیک ناکفایتی مشاهده از خطای خواندن.
SagaLLM و کنترل رویه [8], [9]	اعتبارسنجی مستقل، بازیابی یا تحمیل توالی رویه.	قرارداد مشترک است؛ انتخاب مشاهده، متغیر آزمایش است.

محیط مشترک در τ^2-Bench، تغییر وضعیت توسط طرف دیگر را وارد ارزیابی عامل می‌کند [10]. تعیین مقدار تابع از خواندن هزینه‌دار و مقایسه‌ی سیاست ثابت و تطبیقی، پیشینه‌ی الگوریتمی دارد [11], [12]. کنترل هم‌روندی نیز اعتبارسنجی خوانده‌ها را به کار می‌گیرد [13].

شکاف قابل آزمون

در کارهای نزدیکِ بررسی‌شده، یک مقایسه‌ی واحد با این چهار شرط نیافتیم: مداخله‌ی جفت‌شده روی اعتبار یک اقدام، هزینه‌ی صریح خواندن، گواه قابل بازبینی و تفکیک سقف اطلاعاتی از عملکرد سیاست. سهم پیشنهادی، ساخت و ارزیابی این چارچوب برای ازسرگیری گردش کار است. کارهای نسخه‌ی OpenReview و arXiv در فهرست منابع با وضعیت خود مشخص شده‌اند.

بخش ۳

اهداف و فرضیه‌های پژوهش

هدف اصلی

تعیین اینکه خواندن تطبیقی وضعیت تازه، تحت بودجه‌ی یکسان، چه مقدار به پوشش تصمیم‌های معتبر می‌افزاید و این مزیت در چه شرایطی از بین می‌رود. پژوهش باید بتواند نتیجه‌ی مثبت، نتیجه‌ی منفی و سقف مشاهده را با همان ابزار اندازه‌گیری گزارش کند.

پرسش	فرضیه‌ی قابل رد	مشاهده‌ای که ادعا را محدود می‌کند
۱ اثر سیاست خواندن	سیاست تطبیقی در آزمون کنارگذاشته‌شده، میانگین پوشش گواه‌دار بیشتری از خط پایه‌ی اجرایی تثبیت‌شده دارد.	اختلاف صفر یا منفی، یا برتری فقط در داده‌ی توسعه.
۲ شرایط ایجاد مزیت	مزیت در قراردادهای شاخه‌ای با مسیر پنهان، نسبت به قراردادهای هم‌اندازه‌ی تک‌شاخه بیشتر است.	پس از همسان‌سازی هزینه و تعداد فیلد، اثر در قراردادهای شاخه‌ای بیشتر نباشد.
۳ اثر کیفیت فراداده	با فراداده‌ی نسخه‌ی دقیق و ارزان، شکاف سیاست تطبیقی با خط پایه‌ی نسخه‌خوان کاهش می‌یابد.	شکاف پوشش در وضعیت فراداده‌ی دقیق نسبت به فراداده‌ی درشت کاهش پیدا نکند.

پرسش تشخیصی مکمل این است که چه سهمی از تصمیم‌های نامعین از نبود هر گواه در بودجه، و چه سهمی از انتخاب مسیر خواندن یا پیروی از داور ناشی می‌شود. پاسخ این بخش با شمارش حالت‌های سازگار و بازبینی ردپا به دست می‌آید و به برتری روش وابسته نیست.

مشارکت‌های مورد انتظار

۱ بنچمارک جفت‌شده با قرارداد اقدام و برچسب قطعی، شامل تغییر برجسته‌ی بدون اثر و تغییر کم‌برجستگیِ اثرگذار.

۲ روش تصمیم با گواه قابل بازبینی، همراه با خط پایه‌ی نسخه‌خوان و محاسبه‌ی دو سقف برای مقایسه‌ی منصفانه.

۳ گزارش شرایط کاربرد و شکست، به تفکیک خانواده، هزینه و نوع اطلاعاتی که در زمان ازسرگیری در دسترس است.

ادعای تاییدی از قبل محدود می‌شود: افزایش میانگین حداقل ۵ نقطه‌ی درصدی، جهت اثر مثبت در هر دو خانواده‌ی کنارگذاشته‌شده و نبود ادامه‌ی نامجاز تحت قرارداد و شبیه‌ساز. این آستانه، معیار تصمیم مهندسی است.

بخش ۴

صورت‌بندی تصمیم و گواه

برای هر سناریو، اقدام پیشنهادی a پیش از مقایسه تعیین می‌شود. وضعیت کامل پس از وقفه x، عضو فضای متناهی Ω است. تابع $g(a,x)$ مقدار ۱ را برای اقدام مجاز و صفر را برای اقدام نامجاز برمی‌گرداند. قرارداد، وضعیت قبلی و مشاهده‌ی اولیه‌ی مجاز z برای همه‌ی روش‌ها یکسان‌اند. هر خواندن q، پاسخی معین در وضعیت x و هزینه‌ی مثبت $c(q)$ دارد. مجموع هزینه‌ی خواندن از B بیشتر نمی‌شود.

$$S(h) = \{\, x \in \Omega : x \sim (z,\, h) \,\}$$

h دنباله‌ی خواندن‌ها و پاسخ‌هاست و رابطه‌ی میان x و زوج (z,h) سازگاری با همه‌ی مشاهده‌ها را نشان می‌دهد. اگر $g(a,x)$ در همه‌ی اعضای مجموعه‌ی ناتهی $S(h)$ یک باشد، ادامه گواه دارد. اگر در همه صفر باشد، رد همان اقدام گواه دارد. اگر هر دو مقدار ممکن باشند یا مجموعه تهی شود، تصمیم به تعویق می‌افتد و علت ثبت می‌شود. گواه شامل شناسه‌ی اقدام، نسخه‌ی قرارداد، شناسه‌ی تصویر وضعیت، خواندن‌ها، هزینه و برچسب است. داور مستقل گواه را از ردپا دوباره محاسبه می‌کند.

دو سقف برای تشخیص محدودیت

سقف پس‌نگر سهم حالت‌هایی است که در هرکدام دست‌کم یک مجموعه خواندن با هزینه‌ی حداکثر B، جواب را قطعی می‌کند. این محاسبه برای انتخاب مجموعه از حالت واقعی استفاده می‌کند. سقف سیاست، بیشترین پوشش مورد انتظار درختی است که در هر گره فقط از پاسخ‌های دیده‌شده استفاده می‌کند. وزن حالت‌ها پیش از آزمون اعلام می‌شود؛ هر دو سقف باید با همان وزن‌ها و قرارداد گزارش شوند. در رابطه‌ی زیر، C پوشش سیاست در بودجه‌ی B است.

$$C_{\pi}(B) \le U_{opt}(B) \le U_{hind}(B) \le 1$$

وقتی دو وضعیت با ردپای یکسان سازگارند و برچسب متفاوت دارند، تصمیم قطعی برای هر دو نمی‌تواند صحیح باشد. در شمارش دقیق، اگر مجموعه‌ی سازگار هم‌برچسب باشد جرم همه‌ی اعضا به پوشش اضافه می‌شود. در غیر این صورت، برای هر خواندن ممکن، پوشش بهینه‌ی شاخه‌های پاسخ با بودجه‌ی باقی‌مانده جمع می‌شود؛ بهترین خواندن مقدار گره را می‌دهد. در بودجه‌ی صفر یا بدون خواندن مفید، پوشش آن گره صفر است.

اعتبار صوری مشروط به کامل بودن فضای حالتِ مجاز، صحت پاسخ ابزار و ثابت ماندن تصویر وضعیت تا تصمیم است. تغییر هم‌زمان بین خواندن و عمل، نیازمند بررسی نسخه یا اجرای شرطی در زمان ثبت است.

بخش ۵

طرح آزمایش و ساخت داده

پژوهش از نوع آزمایش محاسباتی کنترل‌شده است. اقدام در نقطه‌ی ذخیره معتبر است. برای هر جفت، اقدام پیشنهادی، وضعیت پیش از وقفه، جایگاه وقفه، قرارداد، هزینه‌ها و متن مشاهده‌ی اولیه ثابت می‌مانند. مداخله فقط مقدار یک وابستگی را به‌گونه‌ای عوض می‌کند که اعتبار اقدام برگردد. هرجا ممکن باشد تعداد تغییرها در دو عضو جفت همسان می‌شود. سطح برجستگی پیام در سطح قالب تعیین می‌شود و در دو عضو هر جفت یکسان است.

برجستگی سرنخ	اعتبار اقدام حفظ شده	اعتبار اقدام برگشته
کم	به‌روزرسانی یادداشت داخلیِ بی‌اثر	تغییر نسخه‌ی سند با همان پیام ازسرگیری
زیاد	تغییر موضوع درخواستِ جانبی	همان تغییر موضوع همراه با تغییر پیش‌شرط اقدام

برجستگی را با حفظ یا تغییر موضوع پیام ازسرگیری دستکاری می‌کنیم. در سیاست‌های نمادین، کانال متن در تحلیل اصلی نادیده گرفته می‌شود. اثر این دستکاری فقط برای تحلیل لایه‌ی خواننده‌ی متن یا سیاست مبتنی بر مدل، در مرحله‌ی اکتشافی گزارش خواهد شد.

بخش	ترکیب و تعداد	استفاده
پایلوت توسعه	۳ خانواده × ۸ جفت = ۲۴ جفت؛ ۶ کنترل مستقل	انتشار سند، هماهنگی تحویل و جلوگیری از ثبت تکراری؛ بررسی پوشش چهار سلول و هزینه.
آزمون تاییدی	۲ خانواده × ۱۲ قالب × ۲ سطح برجستگی = ۴۸ جفت	رزرو ظرفیت ساختگی و به‌روزرسانی بسته‌ی وابسته؛ ۹۶ سناریو، جدا از توسعه.
آزمون حساسیت	همان نمونه‌ها با هزینه‌ی ناهمسان، خواندن گروهی یا فراداده‌ی دقیق	گزارش جداگانه برای تعیین مرز کاربرد.

در هر خانواده‌ی تاییدی، ۶ قالب شاخه‌ای و ۶ قالب تک‌شاخه از نظر تعداد فیلد و هزینه همسان می‌شوند. اعضای جفت و بازنویسی‌های یک قالب در یک بخش می‌مانند. شناسه، ترتیب فیلد، طول پیام و هزینه‌ی ابزار، برچسب را لو نمی‌دهند. برای هسته‌ی دقیق، حداکثر هشت متغیر دودوییِ پنهان یا حداکثر ۲۵۶ حالت مجاز در نظر گرفته می‌شود. برچسب تاییدی فقط به داور داده می‌شود. تعداد نمونه‌ها یک اندازه‌ی مهندسی اولیه برای پوشش شرایط است و از تحلیل توان انسانی به دست نیامده است.

بخش ۶

سیاست‌های مقایسه و سنجه‌ها

سیاست پیشنهادی از قرارداد مشترک استفاده می‌کند و پس از هر پاسخ، حالت‌های ناسازگار را کنار می‌گذارد. برای هر خواندن مجاز، پوشش مورد انتظارِ گواه در افق دو خواندن با احتساب خواندن جاری را با وزن‌های تثبیت‌شده در توسعه محاسبه می‌کند. اگر هیچ مسیر کوتاه گواه نسازد، کاهش مورد انتظارِ اختلاف برچسب در حالت‌های سازگار ملاک است. برابری امتیاز با هزینه‌ی کمتر و سپس ترتیب ثابت شناسه شکسته می‌شود. رویه به محض صدور گواه، پایان بودجه یا نبود مشاهده‌ی مفید متوقف می‌شود.

مقایسه	کارکرد در آزمایش
تکیه بر نقطه‌ی ذخیره و تعویق همیشگی	دو کنترل تشخیصی برای نشان دادن ریسک کهنگی و هزینه‌ی توقف. در مقایسه‌ی پوشش گواه‌دار، تصمیم بدون گواه پوشش نمی‌گیرد.
تصادفی و ترتیب ثابت بر پایه‌ی قرارداد	خواندن از همان مجموعه ابزار و با همان هزینه؛ ترتیب ثابت پیش از دیدن پاسخ‌ها تثبیت می‌شود.
نسخه‌خوانی و بازخوانی هدفمند	تساوی نسخه، فقط در دامنه‌ی تعریف‌شده، مقدار ذخیره‌شده را معتبر می‌کند؛ تغییر نسخه جهت تغییر مقدار را آشکار نمی‌کند.
بهترین مجموعه‌ی ثابت و درخت تطبیقی دقیق	مراجع تحلیلی روی فضای حالت و وزن‌های اعلام‌شده؛ دسترسی به پاسخ پنهان در اجرای درخت مجاز نیست.
بازخوانی همه‌ی پیش‌شرط‌ها	مرجع خارج از بودجه برای کنترل قرارداد و نمایش هزینه‌ی کامل.

خط پایه‌ی اصلی از میان ترتیب ثابت و نسخه‌خوانی بر اساس پوشش در توسعه انتخاب می‌شود؛ در تساوی، نسخه‌خوان انتخاب خواهد شد. مقایسه‌ی تصادفی با ۲۰ بذر ثابت انجام می‌شود. داور و مدل مشاهده برای همه مشترک‌اند. هزینه‌ی فراخوان نسخه، خواندن گروهی و خواندن منفرد با قرارداد ابزار تعیین می‌شود؛ هیچ روش، فراداده‌ی اختصاصی رایگان دریافت نمی‌کند.

سنجه‌ی اصلی و سنجه‌های مکمل

پوشش گواه‌دار، نسبت سناریوهایی است که در آن‌ها ادامه یا ردِ درست همراه گواه تاییدشده و در بودجه رخ می‌دهد. سنجه‌ی اصلی، اختلاف این پوشش بین روش‌ها با وزن برابر برای هر خانواده و بودجه‌های ۲، ۳ و ۴ واحد است. بودجه‌های صفر و یک کنترل تشخیصی‌اند. نرخ ادامه‌ی نامجاز، نرخ تعویقِ اقدام مجاز، پوشش جداگانه‌ی رد و ادامه، هزینه‌ی واقعی خواندن، و درصد گواه‌های نامعتبر با مخرج مشخص گزارش می‌شوند.

برای نرخ ادامه‌ی نامجاز، شمار ادامه‌ها در حالت‌های نامجاز بر شمار همان حالت‌ها تقسیم می‌شود. نرخ تعویقِ اقدام مجاز، سهم موارد تعویق از همه‌ی حالت‌های مجاز است. نرخ گواه نامعتبر، سهم گواه‌های ردشده از گواه‌های ارسالی است. مخرج صفر به صورت سنجه‌ی تعریف‌نشده گزارش می‌شود.

بخش ۷

تحلیل نتایج و اعتبار پژوهش

تحلیل تاییدی

برای هر سناریو و بودجه، اختلاف جفت‌شده‌ی شاخص پوشش بین سیاست تطبیقی و خط پایه ثبت می‌شود. در هر خانواده، ابتدا میانگین روی سناریوها و بودجه‌های اصلی گرفته می‌شود؛ سپس به خانواده‌ها وزن برابر داده می‌شود. نتیجه‌ی اصلی همراه با اختلاف هر خانواده و نمودار پوشش برحسب بودجه منتشر می‌شود. این مقایسه درباره‌ی مجموعه‌ی مشخص سناریوهاست. بازنویسی متن و تکرار بذر به‌عنوان نمونه‌ی مستقل برای استنباط درباره‌ی همه‌ی گردش کارها شمرده نمی‌شود.

تفکیک محل شکست

دسته	قاعده‌ی تشخیص و تفسیر
کفایت‌ناپذیری در بودجه	حتی با انتخاب پس‌نگر مجموعه خواندن، برای این حالت هیچ گواهی در بودجه ساخته نمی‌شود.
گواه موجود اما به دست نیامده	یک گواه پس‌نگر وجود دارد و ردپای سیاست به آن نمی‌رسد. در سطح مجموعه، فاصله تا درخت بهینه مشخص می‌کند چه مقدار از شکاف را یک سیاست مشاهده‌پذیر می‌توانسته کم کند.
عدم پیروی از گواه	ردپا برای تصمیم قطعی کافی بوده، اما تصمیم صادرشده غلط، نامعین یا بدون گواه معتبر است.
ناسازگاری ابزار یا قرارداد	ردپا با هیچ حالت مجازی سازگار نیست. این مورد جداگانه ثبت می‌شود و گواه ادامه نمی‌گیرد.

تهدیدها و کنترل‌ها

سوگیری طراحی به نفع شاخه‌بندی با کنترل تک‌شاخه‌ی هم‌اندازه، بودجه‌ی برابر و آزمون روی خانواده‌های استفاده‌نشده در توسعه بررسی می‌شود. نشت برچسب با بازبینی جفت‌ها و آزمون حساسیت به ترتیب و شناسه محدود می‌شود. از آنجا که قرارداد نمادین در هسته‌ی آزمایش از پیش معلوم است، نتیجه درباره‌ی استخراج پیش‌شرط از زبان طبیعی نیست. خواندن گروهی، فراداده‌ی کامل و قیمت ناهمسان جداگانه آزموده می‌شوند تا مزیت مصنوعی ناشی از قیمت‌گذاری هر فیلد مشخص شود.

قفل طرح پیش از نخستین اجرای تاییدی، شامل نسخه و هش سناریوها، قرارداد، بودجه، قواعد شکست، خط پایه، تنظیمات سیاست و برنامه‌ی گزارش است. نتیجه‌ی ضعیف در یک خانواده یا سودی که فقط در مثال طراحی‌شده دیده شود، به‌عنوان برتری تعمیم‌پذیر گزارش نمی‌شود. هرگونه تغییر پس از قفل، با تاریخ و دلیل ثبت و تحلیل متناظر اکتشافی نام‌گذاری می‌شود.

بخش ۸

شاهد اولیه و برنامه‌ی اجرا

شمارش کامل مثال هشت‌حالته

در نمونه‌ی اجراشده، سه متغیر دودویی مسیر انتشار، تایید عادی و تایید استثنا را تعیین می‌کنند. اجازه‌ی انتشار به تایید مسیر فعال بستگی دارد و هر خواندن یک واحد هزینه دارد. همه‌ی هشت حالت با وزن برابر بررسی شدند. با دو خواندن، انتخاب تطبیقی ابتدا مسیر و سپس تایید همان شاخه را می‌خواند.

بودجه‌ی خواندن	بهترین انتخاب ثابت	بهترین سیاست تطبیقی
۰ یا ۱	۰ از ۸	۰ از ۸
۲	۴ از ۸	۸ از ۸
۳	۸ از ۸	۸ از ۸

این شمارش، نمونه‌ی سازگاری تعریف گواه و وجود مزیت در یک قرارداد شاخه‌ای را نشان می‌دهد. بنچمارک، مقایسه با کنترل نسخه و انتقال به گردش کار مستقل هنوز اجرا نشده‌اند.

زمان‌بندی پیشنهادی

زمان	کار	تحویل و شرط عبور
هفته‌ی ۱	پیاده‌سازی قرارداد و محیط محلی	داور مستقل و بازتولید شمارش هشت‌حالته
هفته‌های ۲ و ۳	ساخت پایلوت و خط پایه‌ها	۲۴ جفت، کنترل نشت و قفل طرح
هفته‌های ۴ و ۵	آزمون کنارگذاشته‌شده و حساسیت	جدول اثر جفت‌شده، هزینه و دسته‌بندی شکست
هفته‌ی ۶	تدوین و بازتولید مستقل	کد، سناریوها، داده‌ی نتیجه و گزارش محدودیت‌ها

هسته‌ی پژوهش روی یک سیستم با Python و سناریوهای مصنوعی قابل اجراست؛ به مشارکت‌کننده‌ی انسانی، داده‌ی خصوصی، سرویس عملیاتی، GPU یا API پولی نیاز ندارد. آزمون مدل زبانی و انتقال به یک بنچمارک مستقل، فاز اکتشافی پس از تثبیت هسته‌اند. نسخه‌ی داده، بذر، ثبت فراخوان‌ها و گواه‌ها در مخزن پژوهش نگه داشته می‌شوند. در فاز مدل زبانی، شناسه‌ی مدل، تنظیمات و متن درخواست پیش از اجرا ثبت می‌شوند.

منابع پژوهش

منابع به ترتیب نخستین ارجاع شماره‌گذاری شده‌اند. وضعیت انتشار در هر مدخل آمده است.

[1] E. M. Altmann, J. G. Trafton, and D. Z. Hambrick, “Momentary interruptions can derail the train of thought,” Journal of Experimental Psychology: General, vol. 143, no. 1, pp. 215-226, 2014. DOI: 10.1037/a0030986

[2] T. T. Nguyen, J. A. Etzel, M. A. Bezdek, and J. M. Zacks, “Multiple event segmentation mechanisms in the human brain,” eLife, version of record, 2026. DOI: 10.7554/eLife.107955.3

[3] B. Güler, S. Karahamza, Y. D. Şentürk, O. Bein, D. Clewett, and E. Günseli, “Working memory facilitates event segmentation via boundary-triggered reactivation and partial accumulation during events,” Journal of Cognitive Neuroscience, vol. 38, no. 10, pp. 1897-1909, 2026. DOI: 10.1162/JOCN.a.2628

[4] A. Gulati, “ContinuityBench: A framework and taxonomy for evaluating agent recovery from interrupted state,” OpenReview manuscript, 2026. Publication status unverified. Record

[5] G. Liu and S. Gabriel, “PM-Bench: Evaluating prospective memory in LLM agents,” arXiv preprint, 2026. arXiv:2607.12385

[6] D. Zeng et al., “Async-RBench: Benchmarking asynchronous task execution in LLM agents,” arXiv preprint, 2026. arXiv:2610.32429

[7] S. Sheng, Z. Wang, and L. Zhou, “When agents overtrust environmental evidence: An extensible agentic framework for benchmarking evidence-grounding defects in LLM agents,” arXiv preprint, 2026. arXiv:2605.08828

[8] E. Y. Chang and L. Geng, “SagaLLM: Context management, validation, and transaction guarantees for multi-agent LLM planning,” Proceedings of the VLDB Endowment, vol. 18, no. 12, pp. 4874-4886, 2025. DOI: 10.14778/3750601.3750611

[9] Y. Sun et al., “Keeping LLM agents on procedure: Executable finite-state control for long-horizon instruction fidelity,” arXiv preprint, 2026. arXiv:2611.10884

[10] V. Barres, H. Dong, S. Ray, X. Si, and K. R. Narasimhan, “τ²-Bench: Evaluating conversational agents in a dual-control environment,” in Proceedings of ICML, PMLR, vol. 306, pp. 6736-6782, 2026. PMLR 306

[11] A. Deshpande, L. Hellerstein, and D. Kletenik, “Approximation algorithms for stochastic Boolean function evaluation and stochastic submodular set cover,” in Proceedings of SODA, pp. 1453-1466, 2014. DOI: 10.1137/1.9781611973402.107

[12] M. A. Nielsen, L. Rohwedder, and K. Schewior, “Non-adaptive evaluation of k-of-n functions: Tight gap and a unit-cost PTAS,” in Proceedings of APPROX/RANDOM, 2025, art. no. 26. DOI: 10.4230/LIPIcs.APPROX/RANDOM.2025.26

[13] H. T. Kung and J. T. Robinson, “On optimistic methods for concurrency control,” ACM Transactions on Database Systems, vol. 6, no. 2, pp. 213-226, 1981. Author paper